



データマイニング


Data Mining

9: 分類④ Classification


土居 裕和 Hirokazu Doi

長岡技術科学大学 Nagaoka University of Technology


サポートベクターマシン Support Vector Machine




平面の方程式 Equation of a plane



サポートベクターマシン Support Vector Machine



サポートベクターマシン Support Vector Machine



$x_i \in C_1$ の場合 $w'^T x_i + b' \geq M$

In case of $x_i \in C_1$


$x_i \in C_2$ の場合 $w'^T x_i + b' \leq -M$

In case of $x_i \in C_2$

すべての x_i に対して For all x_i

$$|w'^T x_i + b'| \geq M$$

サポートベクターマシン Support Vector Machine



すべての x_i に対して As for all x_i


$$|w'^T x_i + b'| \geq M$$



$$|w^T x_i + b| \geq 1$$

$$w = \frac{1}{M} w' \quad b = \frac{1}{M} b'$$

サポートベクターマシン Support Vector Machine




$x_i \in C_1$ の場合 $\mathbf{w}^T \mathbf{x}_i + b \geq 1$

In case of $x_i \in C_1$

$x_i \in C_2$ の場合 $\mathbf{w}^T \mathbf{x}_i + b \leq -1$

In case of $x_i \in C_2$

サポートベクターマシン Support Vector Machine




\mathbf{w} と平行な向きに対する \mathbf{x}_i の射影の長さ d_i を計算する

Calculate the length d_i of projection of \mathbf{x}_i onto the line parallel to \mathbf{w}

$$d_i = \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|}$$


サポートベクターマシン Support Vector Machine



$$\sigma = \min_{x_i \in C_1} d_i - \max_{x_i \in C_2} d_i$$

$$= \min_{x_i \in C_1} \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|} - \max_{x_i \in C_2} \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|}$$

サポートベクターマシン Support Vector Machine



$x_i \in C_1$ の場合 $\mathbf{w}^T \mathbf{x}_i + b \geq 1$

In case of $x_i \in C_1$


なので Then $\min_{x_i \in C_1} \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|} = \frac{1 - b}{\|\mathbf{w}\|}$

$x_i \in C_2$ の場合 $\mathbf{w}^T \mathbf{x}_i + b \leq -1$

In case of $x_i \in C_2$


なので Then $\max_{x_i \in C_2} \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|} = \frac{-1 - b}{\|\mathbf{w}\|}$

サポートベクターマシン Support Vector Machine



$$\begin{aligned}\sigma &= \min_{x_i \in C_1} \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|} - \max_{x_i \in C_2} \frac{\mathbf{w}^T \mathbf{x}_i}{\|\mathbf{w}\|} \\ &= \frac{1 - b}{\|\mathbf{w}\|} - \frac{-1 - b}{\|\mathbf{w}\|} \\ &= \frac{2}{\|\mathbf{w}\|}\end{aligned}$$

サポートベクターマシン Support Vector Machine




$|\mathbf{w}^T \mathbf{x}_i + \mathbf{b}| \geq 1$ という制約の下で

Under the constraint that $|\mathbf{w}^T \mathbf{x}_i + \mathbf{b}| \geq 1$


$\sigma = \frac{2}{\|\mathbf{w}\|}$ を最大化する Maximize $\sigma = \frac{2}{\|\mathbf{w}\|}$

$\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$ を最小化する Minimize $\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$

サポートベクターマシン Support Vector Machine



サポートベクターマシン Support Vector Machine




t_i : x_i のクラスを表す変数

A variable representing the class of x_i

$$t_i = \{-1, +1\}$$

サポートベクターマシン Support Vector Machine



$x_i \in C_1$ の場合 $\mathbf{w}^T \mathbf{x}_i + b \geq 1$

In case of $x_i \in C_1$


$x_i \in C_2$ の場合 $\mathbf{w}^T \mathbf{x}_i + b \leq -1$

In case of $x_i \in C_2$



$$t_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

ハードマージンSVM Hard Margin SVM




ハードマージンSVMは線型分離可能な問題に適用

Hard margin SVM is applicable to linearly separable data

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$


$$\text{subject to } t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

ソフトマージンSVM Soft Margin SVM




線型分離不可能な場合は？
What about linearly inseparable case?

ソフトマージンSVM Soft Margin SVM



サポートベクターマシン Support Vector Machine



$x_i \in C_1$ の場合 $w^T x_i + b \geq 1 - \xi_i$

In case of $x_i \in C_1$


$x_i \in C_2$ の場合 $w^T x_i + b \leq -1 + \xi_i$

In case of $x_i \in C_2$



$$t_i (w^T x_i + b) \geq 1 - \xi_i$$

ソフトSVM Soft Margin SVM



ソフトマージンSVMは線型分離不可能な問題に適用

Soft margin SVM is applicable to linearly inseparable data

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{subject to } t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

ハードマージンSVM Hard Margin SVM

<主問題> Primal Problem

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{subject to} \quad t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - t_i(\mathbf{w}^T \mathbf{x}_i + b))$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \quad \frac{\partial L}{\partial b} = 0 \quad \frac{\partial L}{\partial \alpha} = 0 \quad \begin{array}{l} \text{KKT条件を考慮} \\ \text{Take KKT condition into account} \end{array}$$

ハードマージンSVM Hard Margin SVM


<双対問題> Dual Problem

$$\begin{aligned} \max_{\alpha} L(\alpha) &= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^n \alpha_i \\ \text{subject to } \sum_{i=1}^n \alpha_i t_i &= 0, \alpha_i \geq 0 \end{aligned}$$

α を求めると、それを用いて \mathbf{w} と b の最適解が分かる

Optimal values of \mathbf{w} and b are obtained based on α meeting the constraints above

カーネル法 Kernel Methods



<https://machine-learningnote.readthedocs.io/en/latest/algorithm/svm.html>

データを高次元空間に写像することで、線型分離不可能な問題を線型分離可能にする

Transforming linearly inseparable problem to linearly separable one by mapping data to higher-dimensional space

基底関数 Basis Function

基底関数 φ は m 次元データ \mathbf{x}_i を $p(p > m)$ 次元データ $\varphi(\mathbf{x}_i)$ に変換する

Basis function φ transforms m -dimensional data \mathbf{x}_i to p -dimensional data $\varphi(\mathbf{x}_i)$

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{im})$$

$$\varphi(\mathbf{x}_i) = (\varphi_1(\mathbf{x}_i), \varphi_2(\mathbf{x}_i), \dots, \varphi_p(\mathbf{x}_i))$$

例 Example

$$\mathbf{x}_i = (x_{i1}, x_{i2})$$

$$\varphi(\mathbf{x}_i) = (x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}, \sqrt{2c}x_{i1}, \sqrt{2c}x_{i2}, c)$$

基底関数 Basis Function

<双対問題>

$$\begin{aligned} \max_{\alpha} L(\alpha) &= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j \boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j) + \sum_{i=1}^n \alpha_i \\ \text{subject to } \sum_{i=1}^n \alpha_i t_i &= 0, \alpha_i \geq 0 \end{aligned}$$

α を求めると、それを用いて \mathbf{w} と b の最適解が分かる

Optimal values of \mathbf{w} and b are obtained based on α meeting the constraints above

カーネル関数 Kernel Function

$$\max_{\alpha} L(\alpha) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j \boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j) + \sum_{i=1}^n \alpha_i$$

$\boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j)$ の計算はコストが大きい
A lot of resource is required to compute $\boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j)$

$$\underline{k(\mathbf{x}_i, \mathbf{x}_j)} = \boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j)$$

カーネル関数 Kernel Function

カーネル関数は、基底関数 $\boldsymbol{\varphi}$ による写像の内積と一致する

Kernel function equals to the dot product of mappings by basis function $\boldsymbol{\varphi}$

多項式カーネル Polynomial Kernel

$$k(\mathbf{x}_i, \mathbf{x}_j) = \gamma (\mathbf{x}_i^T \mathbf{x}_j + c)^d$$

例 Example

$$\mathbf{x}_i = (x_{i1}, x_{i2}) \quad \gamma = 1, d = 2$$

$$\boldsymbol{\varphi}(\mathbf{x}_i) = (x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}, \sqrt{2c}x_{i1}, \sqrt{2c}x_{i2}, c)$$

$$\begin{aligned} k(\mathbf{x}_i, \mathbf{x}_j) &= (\mathbf{x}_i^T \mathbf{x}_j + c)^2 \\ &= (x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}, \sqrt{2c}x_{i1}, \sqrt{2c}x_{i2}, c)^T (x_{j1}^2, x_{j2}^2, \sqrt{2}x_{j1}x_{j2}, \sqrt{2c}x_{j1}, \sqrt{2c}x_{j2}, c) \\ &= \boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j) \end{aligned}$$

カーネルトリック Kernel Trick

基底関数をカーネル関数に置き換えることで、少ない計算コストで双対問題を解ける

Dual problem can be solved with reduced computational cost by replacing basis function with kernel function

$$\begin{aligned} \max_{\alpha} L(\alpha) &= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j \boldsymbol{\varphi}(\mathbf{x}_i)^T \boldsymbol{\varphi}(\mathbf{x}_j) + \sum_{i=1}^n \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j k(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^n \alpha_i = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j (\mathbf{x}_i^T \mathbf{x}_j + c)^2 + \sum_{i=1}^n \alpha_i \end{aligned}$$

その他のカーネル Other Kernels

- linear

$$k(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1 \cdot \mathbf{x}_2$$

- polynomial

$$k(\mathbf{x}_1, \mathbf{x}_2) = (\gamma \mathbf{x}_1 \cdot \mathbf{x}_2 + c)^d$$

- Gaussian or radial basis

$$k(\mathbf{x}_1, \mathbf{x}_2) = \exp\left(-\gamma \|\mathbf{x}_1 - \mathbf{x}_2\|^2\right)$$

- sigmoid

$$k(\mathbf{x}_1, \mathbf{x}_2) = \tanh(\gamma \mathbf{x}_1 \cdot \mathbf{x}_2 + c)$$

<https://www.analyticsvidhya.com/blog/2021/07/svm-support-vector-machine-algorithm/>