



データマイニング


Data Mining

13: ニューラルネットワーク① Neural Network

土居 裕和 Hirokazu Doi


長岡技術科学大学 Nagaoka University of Technology

神經細胞 Neuron

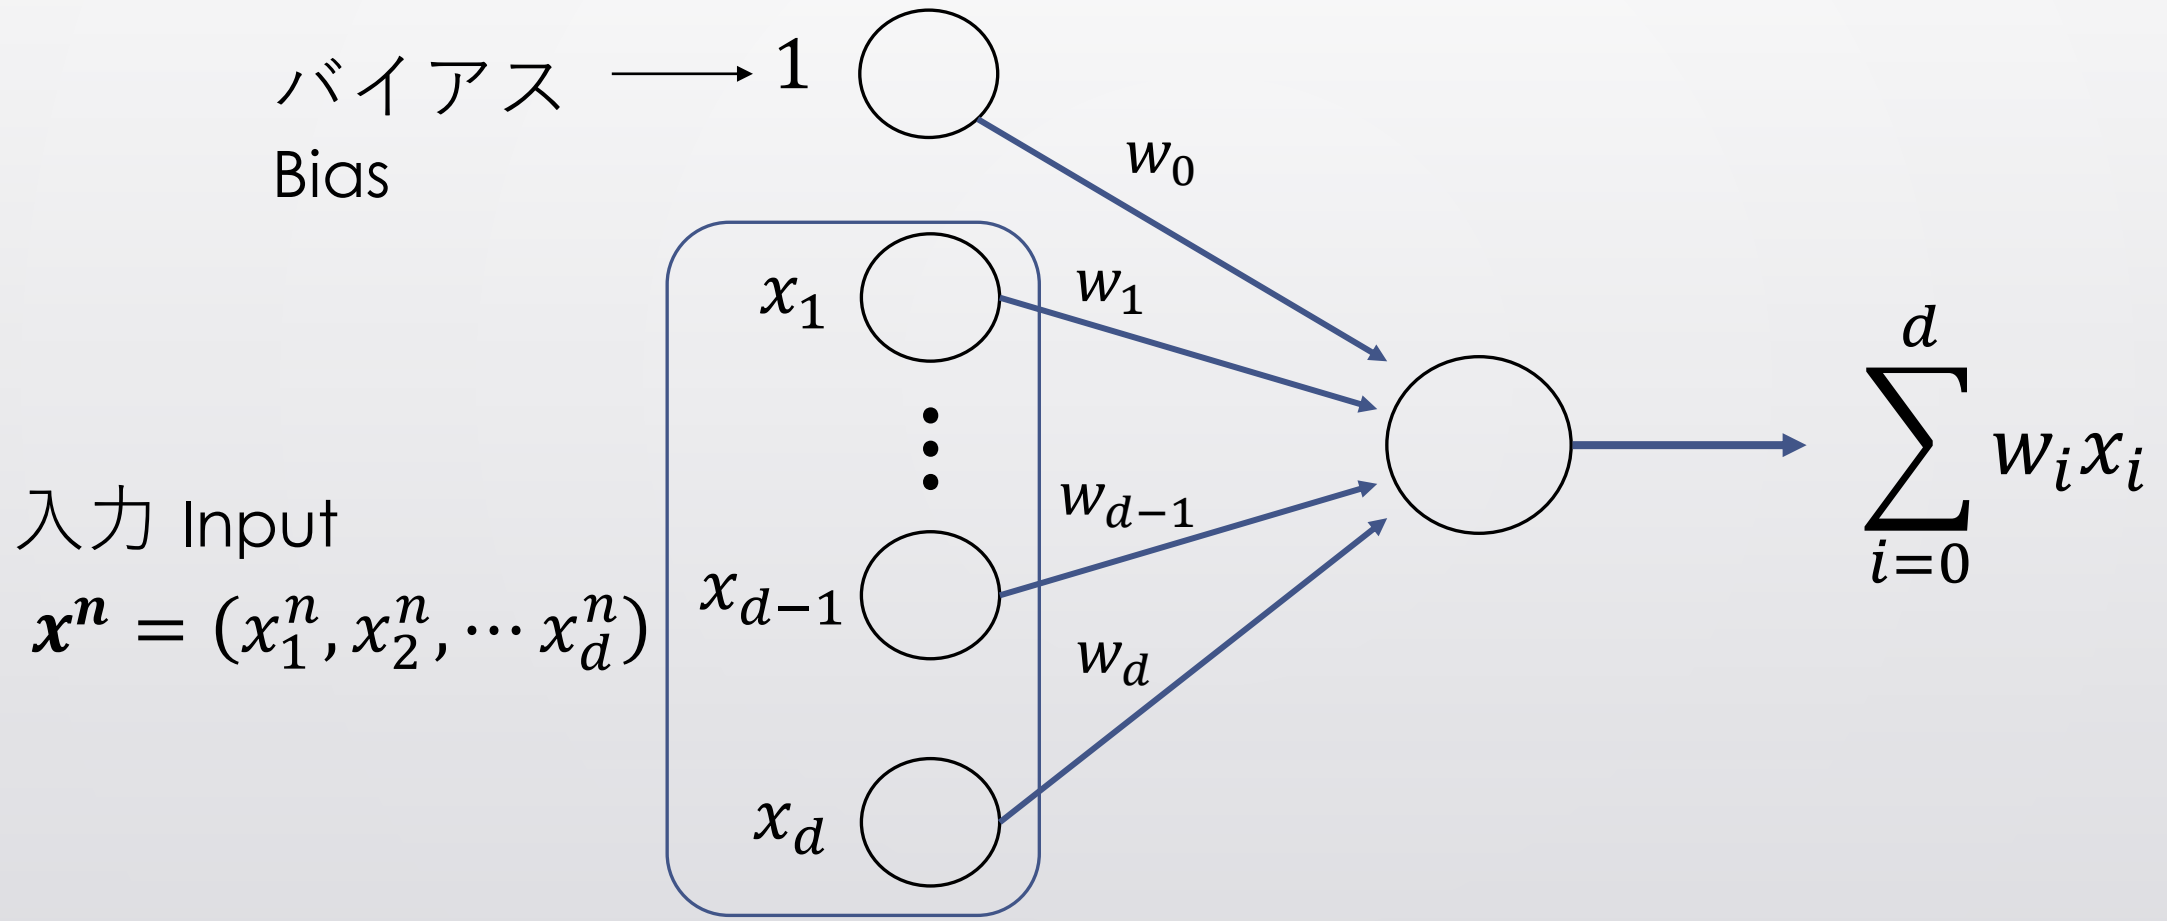


神経細胞の興奮 Neuronal Excitation

神経系の活動 = 神経細胞が電気活動が発生させ、神経細胞間で伝えていくこと
Inter-neuronal transmission of electrical activity




パーセプトロン Perceptron




活性化関数 Activation Function


Tanh




ReLU



Sigmoid




Linear



<https://machine-learning.paperspace.com/wiki/activation-function>


パーセプトロン学習則 Learning Rule of Perceptron



線型分離可能なデータは、符号反転により、すべて $f > 0$ の領域にくる

If linearly separable, all the data can be moved to the region $f > 0$ by sign inversion

パーセプトロン学習則 Learning Rule of Perceptron




$$\mathbf{w}^i, \mathbf{x}^n \in R^d$$

$$\mathbf{w}^i = (w_1^i, w_2^i, \dots, w_d^i)$$

$$\mathbf{w}^{i+1} = \begin{cases} \mathbf{w}^i + \eta \mathbf{x}^n & (f(\mathbf{x}^n) < 0) \\ \mathbf{w}^i & (f(\mathbf{x}^n) > 0) \end{cases}$$

パーセプトロン学習則 Learning Rule of Perceptron




超平面を回転させることで、
識別性能が向上する

Rotation of hyperplane
improves classification
performance


ブール論理演算子とパーセプトロン Boolean Logic Gate and Perceptron

YES




INPUT		OUTPUT
A		
0		0
1		1

NOT




INPUT		OUTPUT
A		
0		1
1		0

AND



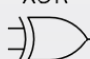
INPUT		OUTPUT
A	B	
0	0	0
1	0	0
0	1	0
1	1	1

OR




INPUT		OUTPUT
A	B	
0	0	0
1	0	1
0	1	1
1	1	1

XOR



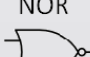
INPUT		OUTPUT
A	B	
0	0	0
1	0	1
0	1	1
1	1	0

NAND




INPUT		OUTPUT
A	B	
0	0	1
1	0	1
0	1	1
1	1	0

NOR

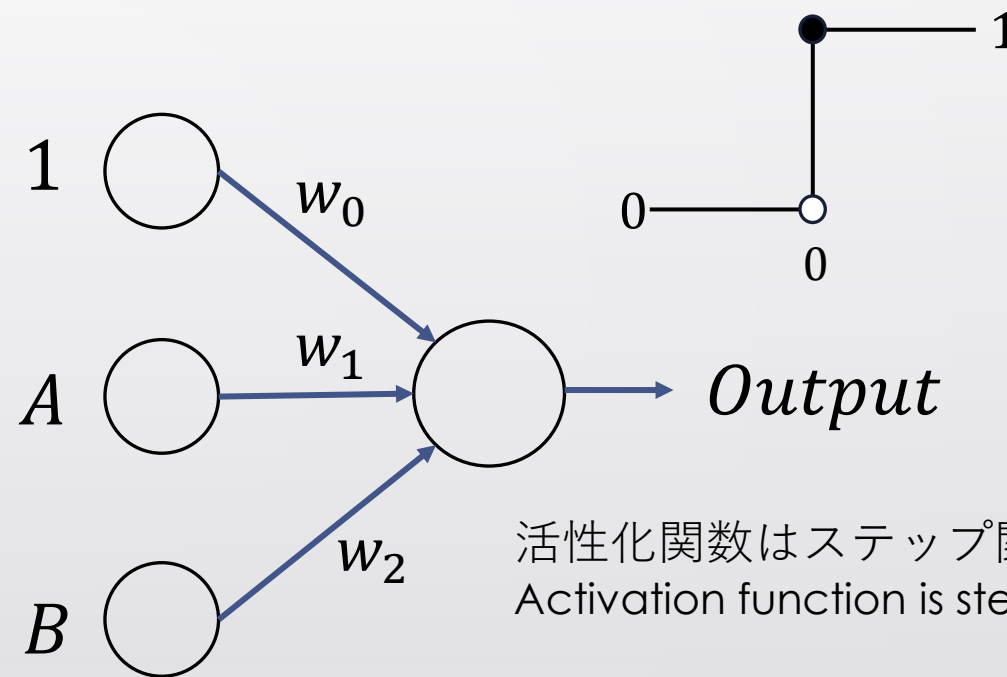


INPUT		OUTPUT
A	B	
0	0	1
1	0	0
0	1	0
1	1	0

XNOR



INPUT		OUTPUT
A	B	
0	0	1
1	0	0
0	1	0
1	1	1




活性化関数はステップ関数とする
Activation function is step function



Abels et al, 2015

ブール論理演算子とパーセプトロン Boolean Logic Gate and Perceptron

AND




INPUT		OUTPUT
A	B	
0	0	0
1	0	0
0	1	0
1	1	1





ブール論理演算子とパーセプトロン Boolean Logic Gate and Perceptron

OR




INPUT		OUTPUT
A	B	
0	0	0
1	0	1
0	1	1
1	1	1





ブール論理演算子とパーセプトロン Boolean Logic Gate and Perceptron

NAND




INPUT		OUTPUT
A	B	
0	0	1
1	0	1
0	1	1
1	1	0





ブール論理演算子とパーセプトロン Boolean Logic Gate and Perceptron

XOR



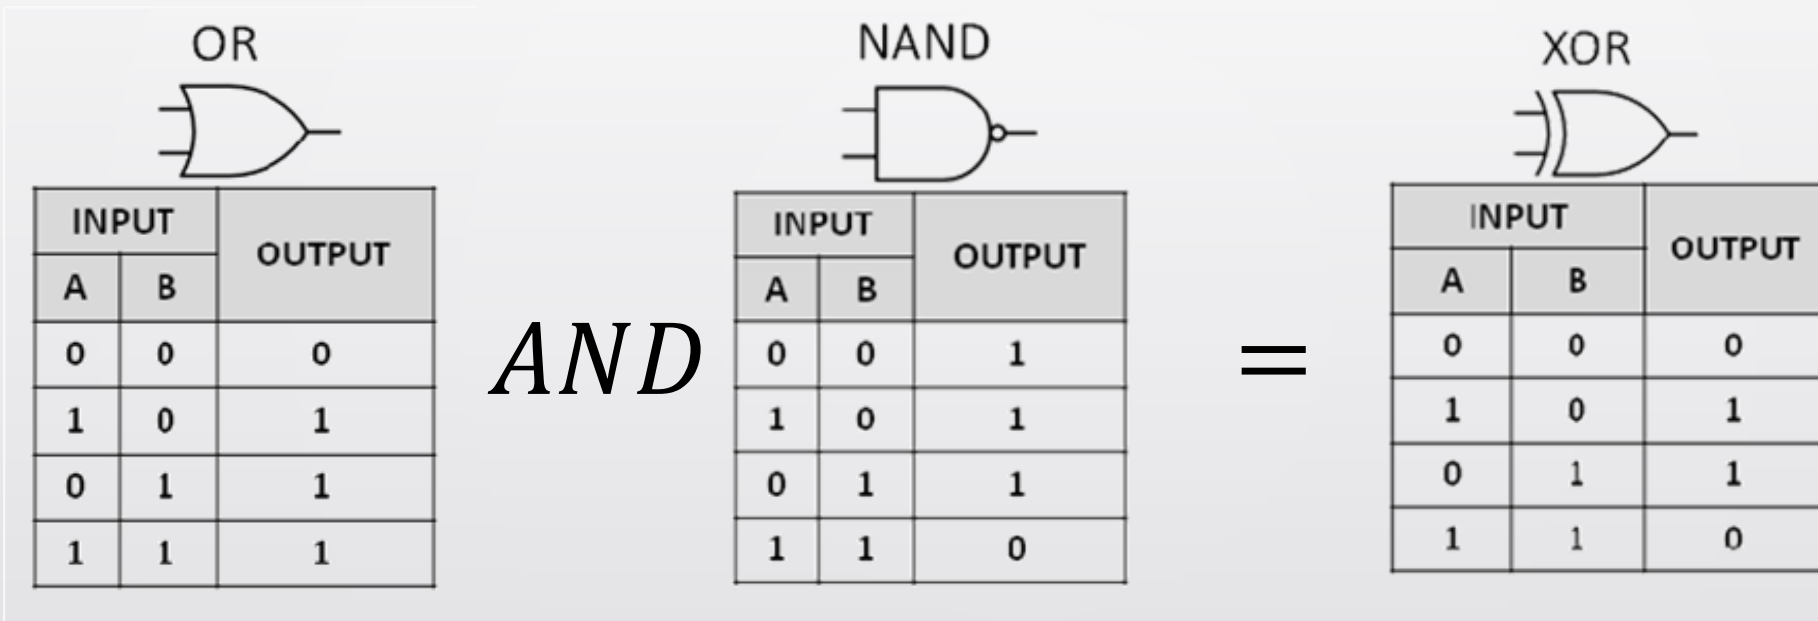
INPUT		OUTPUT
A	B	
0	0	0
1	0	1
0	1	1
1	1	0



単層パーセプトロンでは排他的論理和を構成できない
Single-layered perceptron cannot compose XOR

ブール論理演算子とパーセプトロン


Boolean Logic Gate and Perceptron




XORはORとNANDの論理積

XOR is logical conjunction of OR and NAND

XORと多層パーセプトロン XOR and Multi-layered Perceptron



多層パーセプトロン Multi-layered Perceptron



$w_{ji}^{(1)}$: 入力層から隠れ層への重み
Weights from input to hidden layer


$w_{kj}^{(2)}$: 隠れ層から出力層への重み
Weights from hidden to output layer

$i = 0, 1, 2 \dots d$

$j = 0, 1, 2 \dots M$

$k = 1, 2 \dots C$

多層パーセプトロン Multi-layered Perceptron




$y_k^{(2)}$: 出力 Output

t_k : 教師信号
Teacher Signal

$$t_k \in \{0, 1\} \quad \sum_{k=1}^{k=C} t_k = 1$$

$$k = 1, 2 \dots C$$


隠れ層の出力 Output of Hidden Layer



$$y_j^{(1)} = f \left(\sum_{i=0}^{i=d} w_{ji}^{(1)} x_i^n \right) = f \left(\mathbf{w}_j^{(1)} \mathbf{x}^{nT} \right)$$

$$v_j^{(1)} = \sum_{i=0}^{i=d} w_{ji}^{(1)} x_i^n$$

出力 Output



$$y_k^{(2)} = f \left(\sum_{j=0}^{j=M} w_{kj}^{(2)} y_j^{(1)} \right) = f \left(\mathbf{w}_k^{(2)} \mathbf{y}^{(1)} \right)$$

$$v_k^{(2)} = \sum_{j=0}^{j=M} w_{kj}^{(2)} y_j^{(1)}$$


合成関数の微分 Derivative of Composite Function

$$\frac{df(g(x))}{dx} \quad u = g(x)$$

$$\frac{df(g(x))}{dx} = \frac{du}{dx} \frac{df(u)}{du}$$

$$= g'(x) f'(u) = g'(x) f'(g(x))$$

勾配降下 Gradient Descent



<https://www.linkedin.com/pulse/gradient-descent-its-applications-deep-learning-chirag-subramanian>


$$-\nabla J = \left(-\frac{\partial J}{\partial w}, -\frac{\partial J}{\partial b} \right)$$

$$w \leftarrow w - \eta \frac{\partial J}{\partial w}$$

$-\nabla J$ の方向に変数を変化させることで、関数 J の値を最も素早く減少させることができる

The output value of function J decreases most rapidly along the direction of $-\nabla J$

出力と教師信号の誤差 Error of network output



E を最小化するよう $w_{kj}^{(2)}$ を更新する
Update $w_{kj}^{(2)}$ so as to minimize E

$$E = \frac{1}{2} \sum_{k=1}^c \left(y_k^{(2)} - t_k \right)^2$$

$$w_{kj}^{(2)} = w_{kj}^{(2)} - \eta \frac{\partial E}{\partial w_{kj}^{(2)}} = w_{kj}^{(2)} + \Delta w_{kj}^{(2)}$$

$$\Delta w_{kj}^{(2)} = -\eta \frac{\partial E}{\partial w_{kj}^{(2)}}$$

重みの更新 Weight Updating

$$\begin{aligned}\Delta w_{kj}^{(2)} &= -\eta \frac{\partial E}{\partial w_{kj}^{(2)}} = -\eta \left(y_k^{(2)} - t_k \right) \frac{\partial y_k^{(2)}}{\partial w_{kj}^{(2)}} \\ &= -\eta \left(y_k^{(2)} - t_k \right) \frac{\partial v_k^{(2)}}{\partial w_{kj}^{(2)}} \frac{\partial f(v_k^{(2)})}{\partial v_k^{(2)}} \\ &= -\eta \left(y_k^{(2)} - t_k \right) y_j^{(1)} f' \left(v_k^{(2)} \right) \quad v_k^{(2)} = \sum_{j=0}^{j=M} w_{kj}^{(2)} y_j^{(1)}\end{aligned}$$

重みの更新 Weight Updating

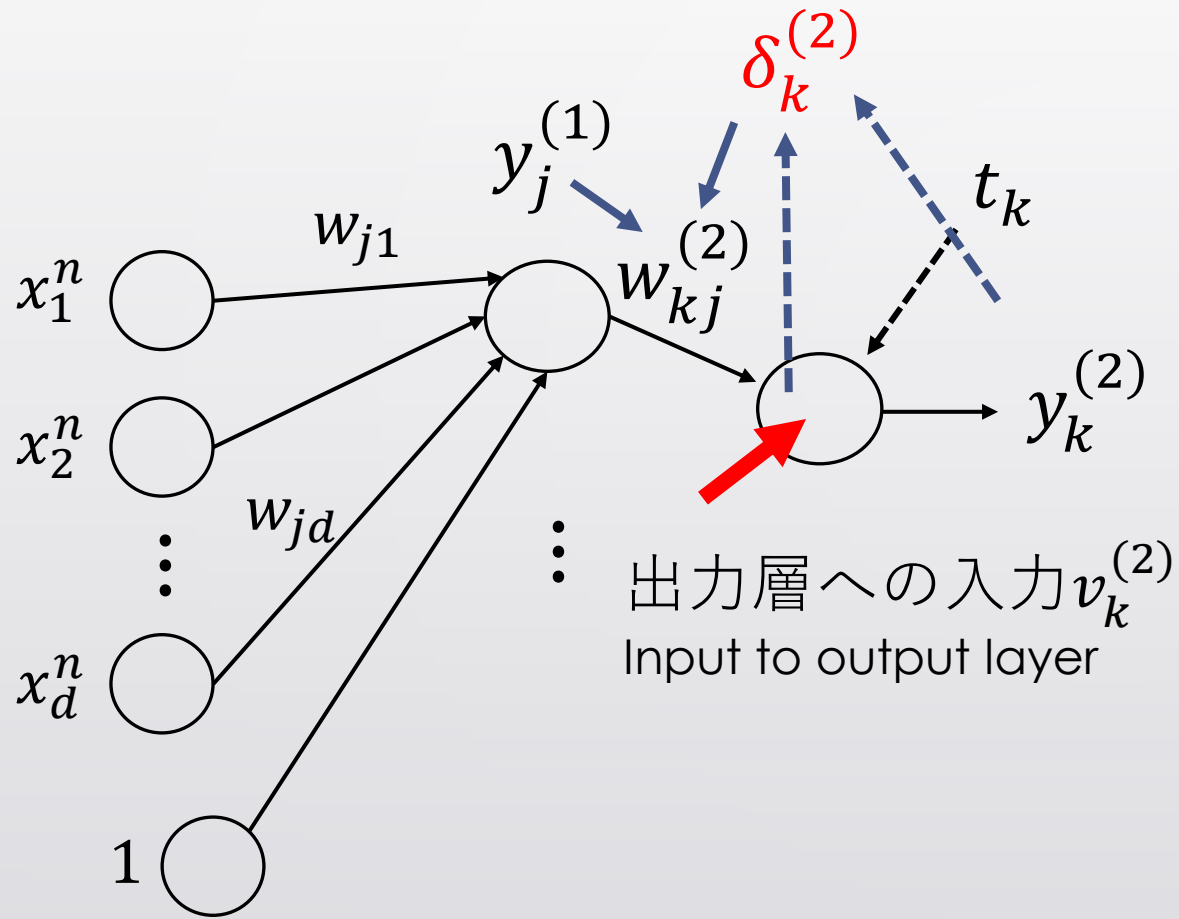
$$\Delta w_{kj}^{(2)} = -\eta \left(\underbrace{y_k^{(2)} - t_k}_{\text{誤差 Error}} \right) \underbrace{y_j^{(1)}}_{\text{隠れ層の出力}} \underbrace{f' \left(v_k^{(2)} \right)}_{\text{出力層への入力}}$$

誤差 Error

出力層への入力
Input to output layer

隠れ層の出力
Output of hidden layer

重みの更新 Weight Updating



$$w_{kj}^{(2)} = w_{kj}^{(2)} + \Delta w_{kj}^{(2)}$$


$$\Delta w_{kj}^{(2)} = -\eta \delta_k^{(2)} y_j^{(1)}$$

$$\delta_k^{(2)} = \left(\underline{y_k^{(2)}} - t_k \right) f' \left(\underline{v_k^{(2)}} \right)$$

誤差 Error

出力層への入力
Input to output layer

重みの更新 Weight Updating



E を最小化するよう $w_{ji}^{(1)}$ を更新する
Update $w_{ji}^{(1)}$ so as to minimize E

$$E = \frac{1}{2} \sum_{k=1}^C \left(y_k^{(2)} - t_k \right)^2$$

$$w_{ji}^{(1)} = w_{ji}^{(1)} - \eta \frac{\partial E}{\partial w_{ji}^{(1)}} = w_{ji}^{(1)} + \Delta w_{ji}^{(1)}$$

$$\Delta w_{ji}^{(1)} = -\eta \frac{\partial E}{\partial w_{ji}^{(1)}}$$

重みの更新 Weight Updating

$$\begin{aligned}\Delta w_{ji}^{(1)} &= -\eta \frac{\partial E}{\partial w_{ji}^{(1)}} = -\eta \frac{\partial}{\partial w_{ji}^{(1)}} \frac{1}{2} \sum_{k=1}^C \left(y_k^{(2)} - t_k \right)^2 \\ &= -\eta \sum_{k=1}^C \left(y_k^{(2)} - t_k \right) \frac{\partial y_k^{(2)}}{\partial w_{ji}^{(1)}}\end{aligned}$$

重みの更新 Weight Updating

$$v_k^{(2)} = \sum_{j=0}^{j=M} w_{kj}^{(2)} y_j^{(1)} \quad y_k^{(2)} = f(v_k^{(2)})$$

$$\Delta w_{ji}^{(1)} = -\eta \sum_{k=1}^c (y_k^{(2)} - t_k) \frac{\partial f(v_k^{(2)})}{\partial w_{ji}^{(1)}}$$

$$= -\eta \sum_{k=1}^c (y_k^{(2)} - t_k) \frac{\partial v_k^{(2)}}{\partial w_{ji}^{(1)}} \frac{\partial f(v_k^{(2)})}{\partial v_k^{(2)}}$$


重みの更新 Weight Updating

$$v_k^{(2)} = \sum_{j=0}^{j=M} w_{kj}^{(2)} y_j^{(1)} \quad v_j^{(1)} = \sum_{i=0}^{i=d} w_{ji}^{(1)} x_i^n \quad y_j^{(1)} = f(v_j^{(1)})$$

$$\frac{\partial v_k^{(2)}}{\partial w_{ji}^{(1)}} = \frac{\partial v_j^{(1)}}{\partial w_{ji}^{(1)}} \frac{\partial v_k^{(2)}}{\partial v_j^{(1)}} = x_i^n \frac{\partial}{\partial v_j^{(1)}} \sum_{l=0}^{l=M} w_{kl}^{(2)} f(v_l^{(1)})$$

$$= x_i^n w_{kj}^{(2)} \frac{\partial f(v_j^{(1)})}{\partial v_j^{(1)}} = x_i^n w_{kj}^{(2)} f'(v_j^{(1)})$$

重みの更新 Weight Updating

$$\begin{aligned}\Delta w_{ji}^{(1)} &= -\eta \sum_{k=1}^C \left(y_k^{(2)} - t_k \right) \frac{\partial v_k^{(2)}}{\partial w_{ji}^{(1)}} \frac{\partial f(v_k^{(2)})}{\partial v_k^{(2)}} \\ &= -\eta \sum_{k=1}^C \left(y_k^{(2)} - t_k \right) x_i^n w_{kj}^{(2)} f'(v_j^{(1)}) \frac{\partial f(v_k^{(2)})}{\partial v_k^{(2)}}\end{aligned}$$

$$\delta_k^{(2)} = \left(y_k^{(2)} - t_k \right) f'(v_k^{(2)})$$

重みの更新 Weight Updating


$$\Delta w_{ji}^{(1)} = -\eta \sum_{k=1}^C \left(y_k^{(2)} - t_k \right) x_i^n w_{kj}^{(2)} f' \left(v_j^{(1)} \right) \frac{\partial f \left(v_k^{(2)} \right)}{\partial v_k^{(2)}}$$

$$= -\eta \underline{x_i^n} f' \left(\underline{v_j^{(1)}} \right) \sum_{k=1}^C w_{kj}^{(2)} \delta_k^{(2)}$$

入力 Input

隠れ層への入力
Input to hidden layer

重みの更新 Weight Updating




$$w_{ji}^{(1)} = w_{ji}^{(1)} + \Delta w_{ji}^{(1)}$$

$$\Delta w_{ji}^{(1)} = -\eta \delta_j^{(1)} x_i^n$$


入力 Input

$$\delta_j^{(1)} = f' \left(v_j^{(1)} \right) \sum_{k=1}^{k=C} w_{kj}^{(2)} \cdot \delta_k^{(2)}$$

重みの更新 Weight Updating



シグモイド関数 Sigmoid Function




https://en.wikipedia.org/wiki/Sigmoid_function

$$f(x) = \frac{1}{1 + e^{-x}}$$

$$f'(x) = \frac{1 + e^{-x}}{(1 + e^{-x})^2} = f(x)(1 - f(x))$$

ソフマックス関数 Softmax Function

ソフマックス関数で出力を各クラスに属する確率に変換する
Convert output of NN to the probability of belonging to each class
by softmax function




$$P_k = \frac{\exp(y_k^{(2)})}{\sum_{k=1}^{C} \exp(y_k^{(2)})}$$

C : クラスの総数
Total number of classes

損失関数 Loss Function

出力と教師データの誤差を反映する損失関数を最小化する

Minimize loss function that reflects divergence between output of network and teacher signal



二乗誤差の和も損失関数の一つ

Sum of squared error is one type of loss function

$$E = \frac{1}{2} \sum_{k=1}^{k=C} \left(y_k^{(2)} - t_k \right)^2$$

交差エントロピー Cross Entropy

KLダイバージェンスを拡張した損失関数

Loss function based on the concept of KL divergence

$$CE = - \sum_{k=1}^{k=C} t_k \log(P_k) \quad P_k = \frac{\exp(y_k^{(2)})}{\sum_{k=1}^{k=C} \exp(y_k^{(2)})}$$

交差エントロピー Cross Entropy

$$KL(p(x)|q(x)) = \int p(x) \log \left(\frac{p(x)}{q(x)} \right)$$

$$p = (t_1, t_2 \cdots t_C) \quad t_k \in \{0, 1\} \quad \sum_{k=1}^{k=C} t_k = 1$$

$$q = (P_1, P_2 \cdots P_C)$$

交差エントロピー Cross Entropy

$$KL(p|q) = \sum_{k=1}^{k=C} t_k \log \left(\frac{t_k}{P_k} \right)$$

$$= \underbrace{\sum_{k=1}^{k=C} t_k \log(t_k)}_{\text{教師信号にのみ関係}} - \underbrace{\sum_{k=1}^{k=C} t_k \log(P_k)}_{\text{交差エントロピー}}$$

教師信号にのみ関係
Relevant only to
teacher signal

交差エントロピー
Cross Entropy